Case de Data Science

Contexto

O **Bolsa Família (atualmente integrado ao Programa Auxílio Brasil/Novo Bolsa Família)** é um dos principais instrumentos de política pública de combate à pobreza no Brasil. A correta **distribuição dos benefícios** depende de fatores socioeconômicos complexos e heterogêneos entre os municípios.

Este case propõe o uso de **dados públicos governamentais**, combinando:

- Informações administrativas do Programa Bolsa Família
- Indicadores socioeconômicos municipais do IBGE (SIDRA)

O objetivo é explorar **quais variáveis explicam e predizem a quantidade de beneficiários** em cada município brasileiro.

Objetivo do Projeto

Construir um **modelo preditivo supervisionado** capaz de estimar:

- **Quantidade de famílias beneficiárias do Bolsa Família por município**
- A partir de **indicadores sociais, econômicos e demográficos do IBGE**, associados ao território, exemplos:
    - "Municípios com menor taxa de alfabetização tendem a concentrar maiores quantidades de beneficiários"
    - "Número de empresas per capita tem efeito negativo sobre a quantidade de benefícios"

Perguntas de Negócio

1. Quais indicadores socioeconômicos mais influenciam a quantidade de beneficiários?
2. É possível estimar a demanda potencial de benefícios em municípios?
3. Há municípios com **subatendimento** ou **sobreconcentração** de beneficiários?

4. Como esse modelo pode apoiar **planejamento orçamentário e políticas públicas**?

Fontes de Dados

Bolsa Família – Benefícios Básicos e Variáveis

Fonte: https://dados.gov.br/dados/conjuntos-dados/bolsa-familia---beneficios-basicos-e-variaveis

Principais variáveis sugeridas:

- Código do município (IBGE)
- Ano/mês de referência
- Conjunto de variáveis relacionadas ao target

Indicadores Socioeconômicos – IBGE / SIDRA

Fonte: https://sidra.ibge.gov.br/acervo#/A/Q

Indicadores Sugeridos (agregados por município) mas não exaustivo

- População total
- Percentual da população urbana
- Taxa de analfabetismo
- Renda média domiciliar per capita
- Taxa de desocupação
- Número de empresas sediadas no município
- Produto Interno Bruto (PIB) municipal
- Valor adicionado da agropecuária/serviços
- Percentual de domicílios com saneamento básico

Tabela de Apoio – Código dos Municípios

Fonte oficial IBGE
https://www.ibge.gov.br/explica/codigos-dos-municipios.php

Garante a **padronização do código IBGE (7 dígitos)** para realizar os joins corretos entre:

- Bolsa Família
- SIDRA (IBGE)

Modelagem Preditiva

Será avaliado as melhores práticas de desenvolvimento de modelos para modelo supervisionado, algoritmos candidatos, *feature importance*, capacidade de discriminação e métricas de avaliação e comparação de resultado.

Stack Tecnológico Sugerido

- Python (pandas, scikit-learn, xgboost)
- SQL (para agregações iniciais)
- Power BI / Tableau (visualização)
- GeoPandas (análise espacial)

Entregáveis Esperados

1. Dataset integrado e documentado
2. Análise exploratória (EDA)
3. Modelo preditivo validado
4. Relatório de insights explicáveis
5. Dashboard interativo por município

Regras e Recomendações do Desafio

Prazo de Execução

- O(a) candidato(a) terá **4 dias corridos** para desenvolver o estudo.
- O trabalho deve ser realizado **fora do horário de trabalho**, respeitando a disponibilidade pessoal do candidato.

Originalidade

- **Não é permitido utilizar cases prontos da internet**, repositórios previamente existentes ou tutoriais que reproduzam soluções completas.
- O estudo deve refletir raciocínio analítico próprio, escolhas metodológicas justificadas e capacidade de adaptação aos dados reais

Apresentação do Case

- O(a) candidato(a) deverá preparar um **material de apresentação com duração total de 30 minutos**.

Boa sorte!

Leopoldo Bulgarelli